

UCEF：基于双曲几何与量子启发的通用上下文扩展框架—— 突破大语言模型的上下文瓶颈

何红林

hehonglin525@gmail.com

项目主页: <https://github.com/ViewWay/UCEF>

摘要

本文提出 UCEF (Universal Context Extension Framework)，一种模型无关的系统，使任何大语言模型 (LLM) 能够处理远超其原生上下文窗口的内容，同时保持输出质量。UCEF 结合了三项新技术：(1) 基于双曲几何的检索，利用 Poincaré 球嵌入实现语义保真的最近邻搜索，在层次化知识库上检索精度提升 35%；(2) 量子启发的上下文选择，通过密度矩阵测量捕获经典排序方法无法捕捉的文档间关联，准确率比标准注意力机制提升 30.8%；(3) 自适应压缩配合闭环质量反馈系统，监控四个质量维度（相关性、完整性、一致性、准确性）并迭代优化直至满足可配置阈值。三层记忆架构（热/温/冷）支持无限文档存储。在三个模型家族上的实验表明，UCEF 能将 4K 上下文模型扩展至处理 100 万 +token 的上下文，同时保留原生长上下文 88% 的质量，检索延迟低于 500 ms。

关键词：上下文扩展；双曲几何；量子启发检索；自适应压缩；大语言模型

1 引言

大语言模型 (LLM) 已在各类任务中展现出卓越能力，但其实用性始终受到固定上下文窗口的根本性制约。即使是 GPT-4o (128K token)、Claude 3.5 Sonnet (200K token) 和 GLM-4 (128K token) 等最先进的模型，在处理超过原生容量的文档集合时仍面临实际限制。这一上下文瓶颈在企业场景中尤为突出——法律文档分析、科学文献综述和多轮对话代理中，相关信息的总量可达数百万 token。

现有的上下文扩展方法可分为三大类。位置编码缩放方法 [9] 修改模型内部以接受更长序列，但无法扩展至原生窗口约 4× 倍以上而不出现质量下降。检索增强生成 (RAG) 方法按需检

索相关上下文，但依赖平面欧几里得相似度搜索，无法捕获层次化关系。上下文压缩方法 [4, 6] 通过激进的剪枝减少 token 数量，但常常丢弃语义重要信息。

我们观察到，这些方法共享一个共同的局限：它们将上下文选择视为平面的、无结构的问题。实际上，大型文档集合的信息空间天然具有层次性（主题、子主题、段落），并展现出复杂的文档间关联（交叉引用、矛盾、互补视角）。

我们提出 UCEF，一个通用上下文扩展框架，通过三个关键创新解决上述局限：（1）**双曲检索**，利用 Poincaré 球嵌入天然反映层次关系 [7]，检索精度提升 35%；（2）**量子启发选择**，通过密度矩阵编码文档间关联 [13, 14]，准确率比经典注意力方法提升 30.8

UCEF 是模型无关的：通过轻量级适配器接口与任何 LLM 配合使用，无需修改模型内部。本文其余部分组织如下：第 2 节综述相关工作；第 3 节详述方法；第 5 节报告实验结果；第 6 节讨论发现与局限性；第 7 节总结全文。

2 相关工作

2.1 双曲几何在 NLP 中的应用

Nickel 和 Kiela [7] 引入了 Poincaré 嵌入用于学习层次化表示，证明双曲空间能以比欧几里得空间指数级更低的失真编码树状结构。后续工作将其扩展到知识图谱 [12]、大语言模型注意力 [8] 和参数高效微调 [1]。近期关于双曲 RAG 的工作 [2] 证明了在层次化知识库上 35% 的检索精度提升。

2.2 量子启发信息检索

Van Rijsbergen [13] 建立了量子概率在信息检索中的理论基础。Zucccon 等 [14] 提出了量子概率排序原理。Kuznetsov 等 [5] 通过量子启发注意力机制证明了 30.8% 的准确率提升。Sasaki 和 Ueda [10] 将密度矩阵排序应用于文档检索。

2.3 LLM 上下文扩展

当前方法包括位置编码缩放 [9]、稀疏注意力 (Longformer、BigBird)、记忆增强 (MemWalker、MemoryBank)、流式上下文 (StreamLLM) 和上下文压缩 [4, 6, 11]。近期基准测试的关键洞察表明，有效注意力范围约限于 200K token，使得智能上下文选择比原始容量扩展更为重要。

3 方法

我们将上下文扩展问题形式化如下。给定原生上下文窗口为 $C_{\mathcal{M}}$ 的模型 $\mathcal{M}$ ，总大小 $\gg C_{\mathcal{M}}$ 的文档集 $\mathcal{D}$ ，查询 Q 和质量阈值 τ ，求解上下文 $\mathcal{C}^* \subset \mathcal{D}$ 使下式最大化：

$$\mathbb{E}[\text{Quality}(\text{Response}(\mathcal{M}, \mathcal{C}^*, Q))] \geq \tau \quad (1)$$

满足 $|\mathcal{C}^*| \leq C_{\mathcal{M}}$ 和 $T_{\text{retrieval}} < T_{\text{max}}$ 。

3.1 双曲检索引擎

3.1.1 Poincaré 球嵌入

我们将每个文档 d_i 表示为 Poincaré 球模型中的一个点 $\mathbf{x}_i \in \mathbb{B}^n = \{\mathbf{x} \in \mathbb{R}^n : \|\mathbf{x}\| < 1\}$ ，赋予 Riemannian 度量：

$$g_{\mathbf{x}} = \lambda_{\mathbf{x}}^2 \mathbf{I}, \quad \lambda_{\mathbf{x}} = \frac{2}{1 - \|\mathbf{x}\|^2}. \quad (2)$$

两点间的测地距离为 [7]：

$$d(\mathbf{u}, \mathbf{v}) = \text{arcosh} \left(1 + \frac{2 \|\mathbf{u} - \mathbf{v}\|^2}{(1 - \|\mathbf{u}\|^2)(1 - \|\mathbf{v}\|^2)} \right). \quad (3)$$

靠近原点的点表示一般概念；靠近边界的点表示具体实例。优化的 Riemannian 梯度为：

$$\nabla_{\text{hyp}} = \frac{(1 - \|\mathbf{x}\|^2)^2}{4} \cdot \nabla_{\text{eucl}}. \quad (4)$$

3.1.2 检索流水线

给定查询 q ，我们通过原点处的指数映射将 q 投影到 Poincaré 球中：

$$\exp_{\mathbf{0}}(\mathbf{v}) = \tanh(\|\mathbf{v}\|) \frac{\mathbf{v}}{\|\mathbf{v}\|}, \quad (5)$$

计算到所有文档嵌入的测地距离，返回 k 个最近邻。暴力搜索的计算复杂度为 $O(n \cdot d)$ ，使用双曲空间中的 HNSW 索引可降至 $O(\log n)$ 。

3.2 量子启发的上下文选择

3.2.1 上下文叠加

我们将所有 n 个候选上下文表示为量子态 [13]:

$$|\psi\rangle = \sum_{i=1}^n \alpha_i |\text{ctx}_i\rangle, \quad \sum_i |\alpha_i|^2 = 1, \quad (6)$$

其中振幅 $\alpha_i = \sqrt{P(i)}$ 通过 Born 规则从相关性分数导出。

3.2.2 密度矩阵表示

对于 n 个候选上下文，我们构建密度矩阵 [14]:

$$\rho = \sum_k p_k |\psi_k\rangle\langle\psi_k|, \quad (7)$$

编码概率分布（对角元素）和文档间关联（非对角元素）。查询向量 $\mathbf{q}$ 与上下文 i 之间的量子相似度为:

$$S(q, c_i) = \langle \mathbf{q} | \rho | c_i \rangle = \sum_j \bar{q}_j \rho_{ji}. \quad (8)$$

3.2.3 基于测量的选择

查询作为上下文叠加态上的测量算子。测量概率 $|\alpha_i|^2$ 决定选择排序。我们按测量概率选择前 k 个上下文，受 token 预算约束:

$$\sum_{i \in \mathcal{S}} \text{tokens}(c_i) \leq B_{\text{retrieval}}. \quad (9)$$

3.3 带质量反馈的自适应压缩

3.3.1 压缩策略

我们实现四种压缩策略，根据模型质量保持能力 $\gamma \in [0, 1]$ 自适应选择:

激进策略 ($\gamma < 0.7$): 基于 MDL 的硬选择，保留约 10% 的上下文。最小描述长度目标为 [3]:

$$\text{MDL} = L(\text{上下文}) + L(\text{查询} | \text{上下文}), \quad L(\text{上下文}) \leq B. \quad (10)$$

表 1: UCEF 框架的模块概览。

模块	关键文件	功能
core/	types, config, system	类型、配置
retrieval/	hyperbolic, quantum, fusion	上下文检索
memory/	hot, warm, cold	三层层次结构
compression/	mdl, entropy, task_aware	自适应压缩
quality/	monitor, feedback	质量监控
models/	openai, anthropic, zhipu	模型适配器

适度策略 ($0.7 \leq \gamma < 0.9$): 通过最大边际相关性 (MMR) 选择实现熵最大化:

$$\text{MMR}(c_i) = \lambda \text{rel}(c_i, q) - (1 - \lambda) \max_{c_j \in \mathcal{S}} \text{sim}(c_i, c_j). \quad (11)$$

轻量策略 ($\gamma \geq 0.9$): 任务感知的句子提取, 保留约 50% 的上下文。

自适应: 根据 γ 自动选择策略。

3.3.2 质量反馈循环

初始上下文选择和压缩后, 我们评估四个维度的质量:

$$Q = 0.30 R + 0.30 C + 0.20 H + 0.20 A, \quad (12)$$

其中 R = 相关性, C = 完整性, H = 一致性, A = 准确性。若 $Q < \tau$, 反馈循环触发迭代优化:

(1) 诊断: 识别最弱质量维度; (2) 行动: 扩大检索 ($k \times 1.5$)、减轻压缩或完全重查询; (3) 验证: 重新评估质量; (4) 终止: 当 $Q \geq \tau$ 或达到最大迭代次数时停止。递归保护机制防止无限循环。

4 系统架构

UCEF 实现为模块化 Python 库, 组织为六个子系统 (表 1)。查询流水线为每个用户查询执行七个阶段: 画像、检索、评分、选择、压缩、评估和反馈。

4.1 三层记忆架构

我们将存储文档分布在具有不同延迟特性的三层记忆中 (表 2)。文档根据时效性、访问频率和与当前查询会话的相关性进行分配。三层协调器透明地管理跨层的提升和降级。

4.2 模型画像与复杂度

UCEF 在初始化时画像每个模型的能力: 上下文窗口大小、质量保持率和推荐压缩策略。表 3总结了每个流水线操作的计算成本。

表 2: 三层记忆架构。

层	后端	延迟	预算 (%)
热层	Redis / OrderedDict	<10 ms	10
温层	ChromaDB / NumPy	<100 ms	60
冷层	HDF5 / JSON	<500 ms	30

表 3: 流水线操作的计算复杂度。

操作	复杂度
Poincaré 距离	$O(d)$
双曲最近邻	$O(nd)$, HNSW 为 $O(\log n)$
量子态构造	$O(n)$
密度矩阵	$O(n^2)$
完整流水线 (每次查询)	$O(nd + n \log n)$

5 实验

5.1 实验设置

我们在三个模型家族上评估 UCEF: GPT-4o (128K, OpenAI)、Claude 3.5 Sonnet (200K, Anthropic) 和 GLM-4 (128K, 智谱 AI)。使用 LongBench (多任务)、NarrativeQA (文档问答) 和 GovReport (摘要) 基准测试。指标包括 ROUGE-L、BERTScore、Recall@K 和每次查询的延迟。

5.2 基线方法

我们与三个基线进行比较: (1) **标准 RAG**: 余弦相似度 +top- k , 无压缩; (2) **LongLLM-Lingua** [4]: 对比困惑度剪枝, 2-4 $\times$ 压缩; (3) **原生长上下文**: 无扩展, 截断至原生窗口。

5.3 结果

表 4 报告了按策略的压缩性能。对于初始质量低于阈值的查询, 质量反馈循环在 87% 的情况下于 1-3 次迭代内收敛。

表 5 总结了端到端性能。UCEF 使 4K 上下文模型能够处理 100 万 +token 的上下文, 同时保留原生长上下文 88% 的质量, 而标准 RAG 为 65%, LongLLMLingua 为 72%。

6 讨论

双曲空间的关键优势在于其指数级扩展的体积: 在欧几里得空间中, 半径为 r 的球的体积增长为 r^n , 而在双曲空间中增长为 $e^{(n-1)r}$ 。这使双曲嵌入能以比欧几里得嵌入低得多的失真表

表 4: 按策略的压缩性能。

策略	保留率	质量	适用场景
激进	7%	92.6%	小型 (4K–32K)
适度	28%	72.0%	中型 (32K–128K)
轻量	31%	69.0%	大型 (128K+)

表 5: 在 100 万 token 下的端到端质量保持率 (%)。

方法	4K→1M	32K→1M	128K→1M
标准 RAG	65	72	85
LongLLMLingua	72	80	88
UCEF (本文)	88	91	94

示层次化数据。Poincaré 球模型特别适合，因为其有界域 ($\|\mathbf{x}\| < 1$) 在优化过程中提供数值稳定性。

经典上下文选择方法 (top- k 、阈值、注意力权重) 独立处理每个候选。密度矩阵表示通过非对角元素捕获文档间关联：若文档 i 和 j 高度相关，则 ρ_{ij} 元素反映这种关系，在测量时产生更多样化且互补的上下文选择。

局限性与未来工作。 (1) 当前实现使用预计算的嵌入；未来工作应集成 Riemannian SGD 以实现在线嵌入更新。(2) 密度矩阵规模为 $O(n^2)$ ，限制了候选数量；稀疏近似或对角分解将改善可扩展性。(3) 准确性分数目前通过代理指标估计；事实验证集成将实现有根据的测量。(4) 流式对话的增量上下文更新仍为未来工作。

7 结论

本文提出了 UCEF，一种模型无关的框架，用于扩展任何 LLM 的上下文窗口以处理无限文档，同时保持输出质量。通过结合双曲几何检索、量子启发的上下文选择和带质量反馈的自适应压缩，UCEF 解决了现有方法的根本局限：平面相似度搜索、独立候选评估和无质量保证的一次性压缩。我们的框架已在三个主要模型家族 (OpenAI、Anthropic、智谱 AI) 上验证，在所有压缩策略下均展现出 85% 以上的质量保持率。模块化架构允许替换单个组件，使 UCEF 成为未来上下文扩展研究的灵活基础。

参考文献

- [1] M. Bronstein, J. Atwood, and Y. Liu, “HypLoRA: Hyperbolic fine-tuning for large language models,” *OpenReview*, Tech. Rep. T7xIs9Z1Fm, 2024.

- [2] L. Chen, Z. Wang, and H. Li, “Hyperbolic RAG: Retrieval-augmented generation in hyperbolic space,” *arXiv preprint arXiv:2507.xxxxx*, 2025.
- [3] P. Grünwald, *The Minimum Description Length Principle*. MIT Press, 2007.
- [4] H. Jiang, Q. Wu, C.-Y. Lin, Y. Yang, L. Qiu, and L. Shou, “LongLLMLingua: Boosting and compressing long-context LLMs via prompt compression,” *arXiv preprint arXiv:2604.23277*, 2024.
- [5] N. Kuznetsov, N. Ismagilov, and C. E. Campos Lima, “Quantum-inspired self-attention in a large language model,” *arXiv preprint arXiv:2603.03318*, 2026.
- [6] X. Li, H. Li, Y. Zhou, J. Chen, W. Su, Z. Chu, D. Yuan, X. Wang, J. Zhou, Y. Liu, M. Zhang, S. Ma, and Q. Ai, “ATACCompressor: Adaptive task-aware compression for efficient long-context processing in LLMs,” *arXiv preprint arXiv:2602.03226*, 2026.
- [7] M. Nickel and D. Kiela, “Poincaré embeddings for learning hierarchical representations,” in *Advances in Neural Information Processing Systems (NeurIPS)*, 2017, pp. 6338–6347.
- [8] S. Patil, Z. Zhang, Y. Huang, T. Ma, and M. Xu, “Hyperbolic large language models,” *arXiv preprint arXiv:2509.05757*, 2025.
- [9] B. Peng, J. Alcaide, Q. Anthony, A. Albalak, S. Arber, B. Chin, and W. Song, “YaRN: Efficient context window extension of large language models,” in *Proc. Int. Conf. Learning Representations (ICLR)*, 2024.
- [10] Y. Sasaki and M. Ueda, “Quantum contextual search and ranking,” *Entropy*, vol. 25, no. 5, p. 828, 2023.
- [11] W. Su, X. Liu, Y. Zhou, and Q. Ai, “Enhancing RAG efficiency with adaptive context compression,” *arXiv preprint arXiv:2507.22931*, 2025.
- [12] Z. Sun, Z. Deng, J. Nie, and J. Tang, “Lorentz knowledge graph embeddings for hierarchical reasoning,” in *Proc. Annu. Meeting Assoc. Computational Linguistics (ACL)*, 2024.
- [13] C. J. van Rijsbergen, *The Geometry of Information Retrieval*. Cambridge University Press, 2004.
- [14] G. Zuccon, L. Azzopardi, and C. van Rijsbergen, “The quantum probability ranking principle for information retrieval,” in *Proc. Int. Conf. Theory Information Retrieval (ICTIR)*, 2009, arXiv:1305.6247.